



## (12) 发明专利申请

(10) 申请公布号 CN 113421279 A

(43) 申请公布日 2021.09.21

(21) 申请号 202110777730.2

(22) 申请日 2021.07.07

(71) 申请人 中国科学院光电技术研究所

地址 610209 四川省成都市双流350信箱

(72) 发明人 杨兰兰 严棚 李美惠

(74) 专利代理机构 北京科迪生专利代理有限公司 11251

代理人 江亚平

(51) Int. Cl.

G06T 7/13 (2017.01)

G06T 7/136 (2017.01)

G06T 7/194 (2017.01)

G06T 5/00 (2006.01)

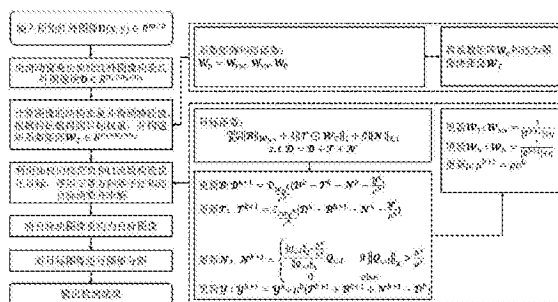
权利要求书3页 说明书9页 附图5页

## (54) 发明名称

一种基于加权核范数最小化的红外弱小目标检测方法

## (57) 摘要

本发明涉及一种基于加权核范数最小化的红外弱小目标检测方法。针对复杂环境下弱小目标容易被漏检或者误检的情况,提出了利用特征检测函数对待处理的图像进行了初步检测,基于此构建出与目标相关的权重,并用这个权重构建一种新的目标函数进行求解,得到最终的目标图像,最后进行阈值分割去除部分干扰;通过本发明提供的方法可以有效降低虚警率,且对红外弱小目标具有良好的检测效果。



1. 一种基于加权核范数最小化的红外弱小目标检测方法, 其特征在于, 该方法包括以下步骤:

步骤1: 输入一幅待处理的红外图像  $\mathbf{D} \in \mathbb{R}^{m \times n}$ , 其中  $\mathbb{R}$  表示实数空间,  $m$  和  $n$  分别代表待处理图像的像素行数和像素列数, 通过采用长宽尺寸为  $n_1 \times n_2$ 、步长为  $s$  的滑动窗遍历待处理红外图像  $\mathbf{D}$  得到红外图像块张量  $\mathbf{D} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ , 其中  $n_1 \times n_2$  等于滑动窗的大小,  $n_3$  为滑动窗的个数;

步骤2: 通过计算待处理的原始红外图像的结构张量得到两个最大的特征值, 根据这两个特征值初步判断原始图像中点特征和线特征的位置来构建特征描述矩阵  $\mathbf{W}_0$ , 并基于  $\mathbf{W}_0$  得到目标权重矩阵  $\mathbf{W}_p$ , 然后其转化成张量的形式;

步骤3: 构建目标函数和拉格朗日函数, 并对其求解, 得到目标图像块张量  $\mathbf{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ ;

步骤4: 将所述目标图像块张量  $\mathbf{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$  重构回目标图像  $\mathbf{T} \in \mathbb{R}^{m \times n}$ ;

步骤5: 将所述目标图像  $\mathbf{T} \in \mathbb{R}^{m \times n}$  进行阈值分割, 获取检测结果。

2. 如权利要求1所述的一种基于加权核范数最小化的红外弱小目标检测方法, 其特征在于:

所述步骤2包括以下步骤:

步骤2.1: 利用待处理的红外图像  $\mathbf{D}$  构建结构张量并求解特征值  $\lambda_1$  和  $\lambda_2$ ;

步骤2.2: 利用  $\lambda_1$  和  $\lambda_2$  获取  $\mathbf{W}_{rec}$  和  $\mathbf{W}_0$ , 进而得到目标权重矩阵  $\mathbf{W}_p$ ;

其中,  $\mathbf{W}_{rec} = \max(\lambda_1, \lambda_2) \cdot \frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2}$ ; 根据所述原始红外图像的特征点检测结果来分别构建点特征矩阵  $\mathbf{W}_{point}$  和线特征矩阵  $\mathbf{W}_{line}$ , 从而得到特征描述矩阵  $\mathbf{W}_0 = \mathbf{W}_{line} + C * \mathbf{W}_{point}$ ,  $C$  为常数, 最后基于  $\mathbf{W}_p = \mathbf{W}_{rec} \cdot \mathbf{W}_{sw} \cdot \mathbf{W}_0$  得到目标权重矩阵  $\mathbf{W}_p$ ; 其中  $\mathbf{W}_{sw} = \frac{1}{|\mathbf{T}| + \eta}$ , 在后续的迭代求解中得到更新, 式中  $\mathbf{T}$  代表目标矩阵,  $\eta$  为非零常数,  $||$  表示求绝对值;

步骤2.3: 用滑动窗按照步骤1所述, 将目标权重矩阵  $\mathbf{W}_p$  堆叠成张量的形式  $\mathbf{w}_T$ , 所述  $\mathbf{w}_T$  为目标权重图像块张量。

3. 如权利要求2所述的一种基于加权核范数最小化的红外弱小目标检测方法, 其特征在于:

所述步骤2.2包括:

步骤2.2.1: 构建特征点检测函数:

$val = \frac{1}{2} e^{\frac{\lambda_1}{\lambda_2 + \eta} - 1} [e^{\lambda_1(\lambda_1 - \lambda_2)} + e^{\lambda_2(\lambda_1 - \lambda_2)}]$ , 该函数又可以分为两个部分:

$val1 = e^{\frac{\lambda_1}{\lambda_2 + \eta} - 1}$ ,  $val2 = \frac{1}{2} [e^{\lambda_1(\lambda_1 - \lambda_2)} + e^{\lambda_2(\lambda_1 - \lambda_2)}]$ , 其中  $e$  为自然数;

步骤2.2.2: 根据特征点检测函数构建点特征矩阵, 对于  $val$  划定阈值, 取其除了无穷大外最大值的  $\gamma_1$  倍为阈值  $seg\_val$ , 对于  $val1$  划定阈值, 取其最小值的  $\gamma_2$  倍为阈值  $seg\_val1$ , 对于同时满足  $val > seg\_val$  和  $val1 \leq seg\_val1$  的特征点便认定为点特征, 从而将其在点特征矩阵对应的位置设为1, 其他的位置设为0, 并采用圆形结构元对点特征矩阵进行形态学膨胀;

步骤2.2.3: 根据特征点检测函数构建线特征矩阵, 对于  $val$  取值为无穷大, 而且满足

val1>seg\_val1的特征点便认为是线特征,从而将其在线特征矩阵对应的位置设为0,其他位置设为1。

4.如权利要求3所述的一种基于加权核范数最小化的红外弱小目标检测方法,其特征

在于:  
步骤3中,通过加权核范数及目标权重构建目标函数,用ADMM算法构造拉格朗日函数,并对其求解,得到目标图像块张量  $\mathcal{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ ,所述步骤3包括:

步骤3.1:输入所述红外图像块张量  $\mathcal{D}$  和目标权重图像块张量  $\mathcal{W}_T$ ;

步骤3.2:通过加权核范数及目标权重构建目标函数,用ADMM算法构造拉格朗日函数;

步骤3.3:求解所述的拉格朗日函数,得到目标图像块张量  $\mathcal{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ 。

5.如权利要求4所述的一种基于加权核范数最小化的红外弱小目标检测方法,其特征

在于:  
所述步骤3.2包括:

步骤3.2.1:通过加权核范数及目标权重构建目标函数,构建的所述目标函数为:

$$\min_{\mathcal{B}, \mathcal{T}} \|\mathcal{B}\|_{\mathcal{W}_B, *}, \lambda \|\mathcal{T} \odot \mathcal{W}_T\|_1 + \beta \|\mathcal{N}\|_{2,1}$$

$$\text{s.t. } \mathcal{D} = \mathcal{B} + \mathcal{T} + \mathcal{N}$$

其中,  $\mathcal{N}$  代表噪声张量,  $\mathcal{B}$  代表背景张量;  $\|\mathcal{A}\|_{\mathcal{W}_A, *} = \frac{1}{|\mathcal{A}| + \eta} \|\mathcal{A}\|_*$ , 这里  $\|\cdot\|_*$  代表核范数,  $\|\mathcal{A}\|_1$  表示张量  $\mathcal{A}$  的  $L_1$  范数, 具体表示为:  $\|\mathcal{A}\|_1 = \sum_i \sum_j \sum_k |\mathcal{A}(i, j, k)|$ ;  $\|\mathcal{N}\|_{2,1}$  为噪声成分的  $L_{2,1}$  范数,  $\|\mathcal{N}\|_{2,1} = \sum_i \sqrt{\sum_j \sum_k \mathcal{N}(i, j, k)^2}$ ,  $\odot$  表示Hadamard积,  $\lambda, \beta$  表示惩罚系数;

步骤3.2.2:通过ADMM算法构造拉格朗日函数:

$$L_\mu(\mathcal{D}, \mathcal{B}, \mathcal{T}, \mathcal{N}, \mathcal{Y}) = \|\mathcal{B}\|_{\mathcal{W}_B, *} + \lambda \|\mathcal{T} \odot \mathcal{W}_T\|_1 + \beta \|\mathcal{N}\|_{2,1} + \langle \mathcal{Y}, \mathcal{D} - \mathcal{B} - \mathcal{T} - \mathcal{N} \rangle + \frac{\mu}{2} \|\mathcal{D} - \mathcal{B} - \mathcal{T} - \mathcal{N}\|_F^2$$

其中  $\|\cdot\|_F$  代表Frobenius范数,  $\mathcal{Y}$  表示拉格朗日乘子,  $\mu$  表示非负的惩罚因子。

6.如权利要求5所述的一种基于加权核范数最小化的红外弱小目标检测方法,其特征

在于:  
所述步骤3.3包括:

步骤3.3.1:初始化ADMM方程参数,迭代次数  $k=0$ ,  $\mathcal{T}^0 = \mathcal{B}^0 = \mathcal{N}^0 = \mathcal{Y}^0 = 0$ ,  $\mu^0 = 0.007$ ,

$\mathcal{W}_{sw} = 1$ , 迭代终止阈值  $\varepsilon = 10^{-7}$ ,  $\lambda = \frac{0.7}{\sqrt{\max(n_1, n_2) \cdot n_3}}$ ,  $\beta = 0.1$ ,  $\eta = 0.01$ ;

步骤3.3.2:迭代直至ADMM算法构造的拉格朗日函数收敛;

其中步骤3.3.2包括:

步骤3.3.2.1:根据如下公式更新参数  $\mathcal{B}^{k+1}$ :

$$\mathcal{B}^{k+1} = \mathcal{D}_{\frac{\mathcal{W}_B}{\mu^k}} \left( \mathcal{D}^k - \mathcal{T}^k - \mathcal{N}^k - \frac{\mathcal{Y}^k}{\mu^k} \right)$$

其中  $\mathcal{D}_\tau(\mathbf{X})$  是奇异值收缩算子,  $\mathcal{D}_\tau(\mathbf{X}) = \mathbf{U} \mathcal{S}_\tau(\mathbf{D}_X) \mathbf{V}^T$ , 式中的  $\mathbf{U}, \mathbf{D}_X, \mathbf{V}$  是对矩阵  $\mathbf{X}$  进行奇异值分解得到的,  $\mathbf{D}_X$  表示由其特征值组成的对角矩阵;

步骤3.3.2.2:根据如下公式更新参数 $\mathcal{T}^{k+1}$ ;

$$\mathcal{T}^{k+1} = S_{\lambda w_T}(\mathcal{D}^k - \mathcal{B}^{k+1} - \mathcal{N}^k - \frac{\mathcal{Y}^k}{\mu^k})$$

其中, $S_{\tau}(X)$ 是软阈值收缩算子, $S_{\tau}(X) = \text{sign}(X) \times \max(|X| - \tau, 0)$ ;

步骤3.3.2.3:根据如下公式更新参数 $\mathcal{N}^{k+1}$ ;

$$\mathcal{N}^{k+1}(:, :, i) = \begin{cases} \frac{\|\mathcal{Q}_{:, :, i}\|_2 - \frac{\beta^k}{\mu^k}}{\|\mathcal{Q}_{:, :, i}\|_2} \mathcal{Q}_{:, :, i} & \text{if } \|\mathcal{Q}_{:, :, i}\|_2 > \frac{\beta^k}{\mu^k} \\ 0 & \text{else} \end{cases}$$

其中 $\mathcal{Q} = \mathcal{D}^k - \mathcal{B}^{k+1} - \mathcal{T}^{k+1} - \frac{\mathcal{Y}^k}{\mu^k}$ ,  $\mathcal{Q}_{:, :, i}$ 表示用滑动窗所截取的第*i*个图像块矩阵, $\|\cdot\|_2$ 表示矩阵的二范数;

步骤3.3.2.4:根据如下公式更新参数 $w_T^{k+1}$ 、 $w_B^{k+1}$ ;

$$w_{sw}^{k+1} = \frac{1}{|\mathcal{T}^{k+1}| + \eta}, w_B^{k+1} = \frac{1}{|\mathcal{B}^{k+1}| + \eta}, \text{其中 } w_{sw}^{k+1} \text{ 是 } w_T^{k+1} \text{ 中需要更新的那部分};$$

步骤3.3.2.5:根据如下公式更新参数 $\mathcal{Y}^{k+1}$ 、 $\mu^{k+1}$ ;

$$\mathcal{Y}^{k+1} = \mathcal{Y}^k + \mu^k (\mathcal{B}^{k+1} + \mathcal{T}^{k+1} + \mathcal{N}^{k+1} - \mathcal{D}^{k+1}), \mu^{k+1} = \min(1.05\mu^k, 10^{10});$$

步骤3.3.2.6:将 $\mathcal{B}^{k+1}$ 和 $\mathcal{N}^{k+1}$ 都归结为背景部分,即: $\mathcal{B}^{k+1} = \mathcal{B}^{k+1} + \mathcal{N}^{k+1}$ ;

步骤3.3.2.7:更新迭代次数 $k = k + 1$ ;

步骤3.3.2.8:分别计算 $\mathcal{T}^k$ 和 $\mathcal{T}^{k+1}$ 中非零元素的个数preT和currT;

步骤3.3.2.9:判断preT和currT是否相等并且都大于0,若是则终止迭代,跳转到步骤

3.3.2.10;若否,则判断公式 $\frac{\|\mathcal{B}^{k+1} + \mathcal{T}^{k+1} + \mathcal{N}^{k+1} - \mathcal{D}^{k+1}\|_F}{\|\mathcal{D}^{k+1}\|_F} < \varepsilon$ 是否成立,若成立,则终止迭代,并跳转

到步骤3.3.2.10,若不成立,则跳转到步骤3.3.2.1;

步骤3.3.2.10:获得最优解 $\mathcal{T} = \mathcal{T}^{k+1}$ ,  $\mathcal{B} = \mathcal{B}^{k+1}$ 。

## 一种基于加权核范数最小化的红外弱小目标检测方法

### 技术领域

[0001] 本发明涉及红外图像处理及目标检测领域,特别提供一种基于加权核范数最小化的红外弱小目标检测方法。

### 背景技术

[0002] 目标检测技术如今已发展的较为成熟,在民用领域,常用于智能监控、交通管控、医学特征识别等,较为常见的有:SIFT、积分图特征和AdaBoost对人脸进行检测,HOG和SVM结合主要用于行人检测;在军事领域,常用于侦察、制导、预警等。红外成像系统与可见光、雷达成像系统相比有着体积小、抗干扰能力强、隐蔽性好、可全天工作等优点,因此多被用于军事领域上,从而使得红外弱小目标检测这一关键技术成为研究热点。红外弱小目标检测的难点主要在与:一方面目标距离成像系统较远,通常成像在 $2X2$ 到 $9x9$ 像素之间,缺乏明显的形状和纹理特征,而且由于远距离成像中能量的散射,小目标的能量损失严重,使得目标与背景之间的对比度低,因此最终目标呈现弱和小的特征;另一方面,小目标所处的背景多变且很复杂,有一些背景的强边缘特征与小目标的特征很像,极易引起目标的误判。由此可见红外弱小目标检测极具挑战性,虽然目前已经提出了很多用于红外弱小目标检测的方法,但是无法适应多变的背景环境,无法在各种环境下都保持其优良的检测性能。基于这些难点,红外弱小目标检测受到了很多研究人员的关注。

[0003] 在国外,对弱小目标检测的主要研究机构有美国的海军实验室、空军实验室,国际光学工程学会(SPIE)从1989年开始,几乎每年都会举办有关弱小目标检测技术的国际会议,研讨弱小目标检测技术的最新成果;在国内,由于起步较晚,与国外还有一定的差距,但国家在弱小目标检测技术方面进行了大量的投入,国内在弱小目标检测方面的相关研究机构有:国防科技大学、华中科技大学等高校以及兵器工业集团第211研究所、兵器工业集团第205研究所、中电集团第27研究所、中国船舶工业总公司717所等。

[0004] 红外弱小目标检测方法可以大致分为两大类:检测前跟踪(TBD)和跟踪前检测(DBT),检测前跟踪方法通常需要根据多帧图片信息处理,最终检测目标,需要很大的计算量和存储量,无法满足实际需求中的实时性要求,因此这种方法很少在实际中应用;跟踪前检测方法只需检测单帧图片即可,处理速度较快,但是可利用的信息量较少,根据研究的关注点,该类方法大致可分为三类:

[0005] (1) 基于背景抑制的方法。这类方法通常采用各种策略去抑制背景,通常认为背景处在图像信号的低频部分,而目标处在图像信号的高频部分,通过各种变换将红外图像的低频部分和高频部分进行分离,然后对各低频分量进行抑制,再对高频分量进行分析,可以将目标检测出来,基于背景的检测方法根据背景抑制的方式不同又可分为空域滤波的方法和变换域滤波的方法。传统基于空域滤波的方法有最大中值\最大均值(max-mean\max-median)滤波器的方法、二维最小均方(two-dimensional least mean square, TDLMS)滤波器的方法、数学形态学方法、中值滤波方法、双边滤波器、高通模板滤波方法等。变换域滤波的方法首先将图片进行变换,得到变换域的信息,常见的有傅里叶变换和小波变换,然后在

变换域处理获取的信息,最后再进行逆变换,得到空间域的信息,并获取相应结果。对于频域,常见的弱小目标检测方法主要有理想高通滤波、巴特沃斯高通滤波等。由于小波变换在多尺度、多方向的信号分析方面具有非常优异的性能,能够较好的检测到信号中的奇异部分,因此,小波变换也被广泛地应用于海面弱小目标红外检测当中,常见的小波变换滤波方法主要有基于Countourlet变换的方法、基于非下采样轮廓波变换的方法等。

[0006] (2) 基于目标增强的方法。由于弱小目标没有几何形状或纹理特征,可利用的有效特征信息较少,所以基于目标角度出发,只能根据目标和周围背景在单帧红外图像中的灰度、结构、对比度等特征差异,设计检测算子,直接提取目标。受到小目标在图像分布中呈现高斯形状的启发,有一些基于局部强度和梯度的方法被提出。小目标可使用二维高斯函数模拟,二维高斯函数形成标量场,其梯度场表现为梯度向量指向中心的特点,同理,小目标具有灰度标量场,其梯度场也表现为梯度向量指向目标中心的特点。这两个属性分别被认为是局部强度属性和局部梯度属性。基于这两个属性,通过计算原始红外图像局部强度和梯度(local intensity and gradient,LIG)图,可以实现目标增强和杂波抑制。受到生物视觉的启发,基于视觉对比机制的弱小目标检测方法被提出,该方法是近几年才出现的一种新颖的弱小目标检测方法,主要根据小目标灰度强于邻域灰度的特征,采用局部对比测量的方法(local contrast measure,LCM),但是该方法存在过增强噪点的现象,于是就有系列的改进方法,例如:采用HVS大小自适应过程和注意力转移机制、利用图像信息熵和局部相似性等信息、局部同质测度方法、多尺度块的对比测量、局部同质测度方法、相对局部对比测量方法、局部差异量度等。但这些方法由于较强的边缘和其他干扰会导致虚警高,所以有些模糊度量的方法被提出。

[0007] (3) 基于目标和背景数据结构的方法。该方法主要是通过查找低维子空间结构或者使用预设的超完备字典来显示数据结构,从而实现小目标的检测。红外图像中目标具有稀疏性,背景具有低秩性,基于这两个特点实现目标图像和背景图像的分离,这种方法同时考虑了目标和背景,近来,基于图像数据结构的方法引起了越来越多的关注。基于图像数据结构的方法通常利用以下两种方式来对小目标进行检测:

[0008] ①利用预设超完备字典的方法首先对图像进行预设超完备字典,之后使用该字典显示图像的数据结构,用低秩稀疏表示模型对图像矩阵进行分解,以获得弱小目标对应的数据分量,从而实现对小目标的检测。对于超完备字典的构建可用二维高斯模型、广义高斯模型和字典学习的方法,还有一些研究中加入了分形理论,通过在分形背景超完备字典上的稀疏表示,可以消除背景杂波。

[0009] ②查找低秩子空间结构,代表性的是基于红外图像块(infrared patch-image, IPI)模型,将红外小目标的检测问题描述成恢复低秩稀疏矩阵的优化问题,通常用核范数作为秩的最佳凸逼近,与矩阵不同,张量是多维矩阵的多线性生成,通常直接作用于高阶数据,所以一般都采用张量的方法来处理,此后的一些改进方法也都是在该模型的基础上,将核范数改为其他范数,更便于优化,或者加入一些先验知识,例如在目标前面加上权重,或者是添加正则项来约束目标或者背景,以此来解决强边缘和未充分利用先验信息给小目标检测带来的影响,并取得了更好背景估计效果,例如,加权红外块图像(WIPI)模型、重加权块图像张量(RIPT)模型、基于图像块张量核范数部分和(IPT-PSTNN)模型等。

## 发明内容

[0010] 虽然重加权块图像张量(RIPT)模型中所提出的权重可以抑制一部分背景的干扰,但是在复杂背景中还有很多强边缘未被抑制反而被增强,针对这个问题,本发明提供了一种基于加权核范数最小化的红外弱小目标检测方法,以解决现有模型方法由于复杂背景中的强边缘干扰而导致检测虚警增强的问题。

[0011] 本发明提出的技术方案如下:

[0012] 一种基于加权核范数最小化的红外弱小目标检测方法,该方法包括以下步骤:

[0013] 步骤1:输入一幅待处理的红外图像 $\mathbf{D} \in \mathbb{R}^{m \times n}$ ,其中 $\mathbb{R}$ 表示实数空间, $m$ 和 $n$ 分别代表待处理图像的像素行数和像素列数,通过采用长宽尺寸为 $n_1 \times n_2$ 、步长为 $s$ 的滑动窗遍历待处理红外图像 $\mathbf{D}$ 得到红外图像块张量 $\mathcal{D} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ ,其中 $n_1 \times n_2$ 等于滑动窗的大小, $n_3$ 为滑动窗的个数;

[0014] 步骤2:通过计算待处理的原始红外图像的结构张量得到两个最大的特征值,根据这两个特征值初步判断原始图像中点特征和线特征的位置来构建特征描述矩阵 $\mathbf{W}_0$ ,并基于该矩阵 $\mathbf{W}_0$ 得到目标权重矩阵 $\mathbf{W}_p$ ,然后将其转化成张量的形式;

[0015] 步骤3:构建目标函数和拉格朗日函数,并对其求解,得到目标图像块张量 $\mathcal{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ ;

[0016] 步骤4:将所述目标图像块张量 $\mathcal{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ 重构回目标图像 $\mathbf{T} \in \mathbb{R}^{m \times n}$ ;

[0017] 步骤5:将所述目标图像 $\mathbf{T} \in \mathbb{R}^{m \times n}$ 进行阈值分割,获取检测结果。

[0018] 本发明的方法基于数据结构,同时考虑目标和背景,用加权的核范数作为背景秩的凸近似,同时使用加权的 $L_1$ 范数约束目标的稀疏性,为了进一步抑制噪声,使用 $L_{21}$ 范数约束噪声,有效的降低了虚警率,提高了算法的鲁棒性,在复杂的环境中具有良好的检测效果。

[0019] 在此基础上,所述步骤1包括:

[0020] 步骤1.1:采用长宽尺寸为 $n_1 \times n_2$ 、步长为 $s$ 的滑动窗遍历所述红外图像 $\mathbf{D}$ ,滑动窗截取的像素在第三维度上进行堆叠构建张量;

[0021] 步骤1.2:重复步骤1.1直至遍历整幅红外图像,由此完成红外图像块张量 $\mathcal{D} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ 的构建。

[0022] 其中,所述步骤2包括以下步骤:

[0023] 步骤2.1:利用待处理的红外图像 $\mathbf{D}$ 构建结构张量并求解特征值 $\lambda_1$ 和 $\lambda_2$ ,其公式如下:

$$[0024] \quad \mathbf{J} = \mathbf{K}_\rho * (\nabla \mathbf{D}_\sigma \otimes \nabla \mathbf{D}_\sigma) = \begin{pmatrix} \mathbf{K}_\rho * \mathbf{I}_x^2 & \mathbf{K}_\rho * \mathbf{I}_x \mathbf{I}_y \\ \mathbf{K}_\rho * \mathbf{I}_x \mathbf{I}_y & \mathbf{K}_\rho * \mathbf{I}_y^2 \end{pmatrix} = \begin{pmatrix} \mathbf{J}_{11} & \mathbf{J}_{12} \\ \mathbf{J}_{21} & \mathbf{J}_{22} \end{pmatrix}$$

[0025] 其中, $\mathbf{J}$ 为结构张量, $\mathbf{K}_\rho$ 是方差为 $\rho$ 的高斯核, $*$ 代表卷积, $\nabla$ 表示梯度, $\otimes$ 表示Kronecker积, $\mathbf{D}_\sigma$ 表示对待处理的图像用方差为 $\sigma$ 的高斯平滑滤波器进行滤波后得到的图像。 $\mathbf{I}_x = \frac{\partial \mathbf{D}_\sigma}{\partial x}$ , $\mathbf{I}_y = \frac{\partial \mathbf{D}_\sigma}{\partial y}$ ,分别表示 $\mathbf{D}_\sigma$ 沿着 $x$ 和 $y$ 方向的梯度。

[0026] 根据结构张量获取最大的两个特征值 $\lambda_1$ 和 $\lambda_2$ ,其公式如下:

$$[0027] \quad \lambda_1 = \frac{1}{2} \left[ \mathbf{J}_{11} + \mathbf{J}_{22} + \sqrt{(\mathbf{J}_{22} - \mathbf{J}_{11})^2 + 4\mathbf{J}_{12}^2} \right]$$

$$[0028] \quad \lambda_2 = \frac{1}{2} \left[ \mathbf{I}_{11} + \mathbf{I}_{22} - \sqrt{(\mathbf{I}_{22} - \mathbf{I}_{11})^2 + 4\mathbf{I}_{12}^2} \right]$$

[0029] 步骤2.2:利用 $\lambda_1$ 和 $\lambda_2$ 获取 $\mathbf{W}_{rec}$ 和 $\mathbf{W}_0$ ,进而得到目标权重矩阵 $\mathbf{W}_p$ ;

[0030] 其中, $\mathbf{W}_{rec} = \max(\lambda_1, \lambda_2) \cdot \frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2}$ ;根据所述原始红外图像的特征点检测结果来分别构建点特征矩阵 $\mathbf{W}_{point}$ 和线特征矩阵 $\mathbf{W}_{line}$ ,从而得到特征描述矩阵 $\mathbf{W}_0 = \mathbf{W}_{line} + C * \mathbf{W}_{point}$ ,C为常数,最后基于 $\mathbf{W}_p = \mathbf{W}_{rec} \cdot \mathbf{W}_{sw} \cdot \mathbf{W}_0$ 得到目标权重矩阵 $\mathbf{W}_p$ ,其中 $\mathbf{W}_{sw} = \frac{1}{|\mathbf{T}| + \eta}$ ,在后续的迭代求解中得到更新,式中T代表目标矩阵, $\eta$ 为非零常数, $||$ 表示求绝对值;

[0031] 步骤2.3:用滑动窗按照步骤1所述,将目标权重矩阵 $\mathbf{W}_p$ 堆叠成张量的形式 $\mathbf{w}_T$ ,所述 $\mathbf{w}_T$ 为目标权重图像块张量。

[0032] 其中,所述步骤2.2包括:

[0033] 步骤2.2.1:构建特征点检测函数:

[0034]  $val = \frac{1}{2} e^{\frac{\lambda_1}{\lambda_2 + \eta} - 1} [e^{\lambda_1(\lambda_1 - \lambda_2)} + e^{\lambda_2(\lambda_1 - \lambda_2)}]$ ,该函数又可以分为两个部分:

[0035]  $val1 = e^{\frac{\lambda_1}{\lambda_2 + \eta} - 1}$ ,  $val2 = \frac{1}{2} [e^{\lambda_1(\lambda_1 - \lambda_2)} + e^{\lambda_2(\lambda_1 - \lambda_2)}]$ ,其中e为自然数;

[0036] 步骤2.2.2:根据特征点检测函数构建点特征矩阵,对于val划定阈值,取其除了无穷大外最大值的 $\gamma_1$ 倍为阈值seg\_val,对于val1划定阈值,取其最小值的 $\gamma_2$ 倍为阈值seg\_val1,对于同时满足 $val > seg\_val$ 和 $val1 \leq seg\_val1$ 的特征点便认定为点特征,从而将其在点特征矩阵对应的位置设为1,其他的位置设为0,并采用圆形结构元对点特征矩阵进行形态学膨胀;

[0037] 步骤2.2.3:根据特征点检测函数构建线特征矩阵,对于val取值为无穷大,而且满足 $val1 > seg\_val1$ 的特征点便认为是线特征,从而将其在线特征矩阵对应的位置设为0,其他位置设为1。

[0038] 其中,步骤3中,通过加权核范数及目标权重构建目标函数,用ADMM算法构造拉格朗日函数,并对其求解,得到目标图像块张量 $\mathbf{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ ,所述步骤3包括:

[0039] 步骤3.1:输入所述红外图像块张量 $\mathbf{D}$ 和目标权重图像块张量 $\mathbf{w}_T$ ;

[0040] 步骤3.2:通过加权核范数及目标权重构建目标函数,用ADMM算法构造拉格朗日函数;

[0041] 步骤3.3:求解所述的拉格朗日函数,得到目标图像块张量 $\mathbf{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ 。

[0042] 其中,所述步骤3.2包括:

[0043] 步骤3.2.1:通过加权核范数及目标权重构建目标函数,构建的所述目标函数为:

$$[0044] \quad \min_{\mathbf{B}, \mathbf{T}} \|\mathbf{B}\|_{\mathbf{W}_B, *} + \lambda \|\mathbf{T} \odot \mathbf{w}_T\|_1 + \beta \|\mathbf{N}\|_{2,1}$$

$$[0045] \quad s.t. \quad \mathbf{D} = \mathbf{B} + \mathbf{T} + \mathbf{N}$$

[0046] 其中 $\mathbf{N}$ 代表噪声张量, $\mathbf{B}$ 代表背景张量, $\|\mathbf{A}\|_{\mathbf{W}_A, *} = \frac{1}{|\mathbf{A}| + \eta} \|\mathbf{A}\|_*$ ,这里 $\|\cdot\|_*$ 代表核范数,是对矩阵A所有的奇异值求和, $\|\mathbf{A}\|_1$ 表示张量A的 $L_1$ 范数, $\|\mathbf{A}\|_1 = \sum_i \sum_j \sum_k |\mathbf{A}(i, j, k)|$ , $\|\mathbf{N}\|_{2,1}$ 为噪声成分的 $L_{21}$ 范数, $\|\mathbf{N}\|_{2,1} = \sum_i \sqrt{\sum_j \sum_k \mathbf{N}(i, j, k)^2}$ , $\odot$ 表示Hadamard积, $\lambda, \beta$ 表示惩罚系数;



[0047] 步骤3.2.2:通过ADMM算法构造拉格朗日函数:

$$L_{\mu}(\mathbf{D}, \mathbf{B}, \mathbf{T}, \mathbf{N}, \mathbf{y}) = \|\mathbf{B}\|_{\mathbf{w}_B} + \lambda \|\mathbf{T} \odot \mathbf{w}_T\|_1 + \beta \|\mathbf{N}\|_{2,1} + \langle \mathbf{y}, \mathbf{D} - \mathbf{B} - \mathbf{T} - \mathbf{N} \rangle$$

$$+ \frac{\mu}{2} \|\mathbf{D} - \mathbf{B} - \mathbf{T} - \mathbf{N}\|_F^2$$

[0049] 其中 $\|\cdot\|_F$ 代表Frobenius范数,  $\mathbf{y}$ 表示拉格朗日乘子,  $\mu$ 表示非负的惩罚因子。

[0050] 其中,所述步骤3.3包括:

[0051] 步骤3.3.1:初始化ADMM方程参数,迭代次数 $k=0$ ,  $\mathbf{T}^0 = \mathbf{B}^0 = \mathbf{N}^0 = \mathbf{y}^0 = \mathbf{0}$ ,  $\mu^0 = 0.007$ ,  $\mathbf{w}_{sw} = 1$ , 迭代终止阈值 $\varepsilon = 10^{-7}$ ,  $\lambda = 0.7/\sqrt{\max(n_1, n_2) * n_3}$ ,  $\beta = 0.1$ ,  $\eta = 0.01$ ;

[0052] 步骤3.3.2:迭代直至ADMM算法构造的拉格朗日函数收敛;

[0053] 其中,步骤3.3.2包括:

[0054] 步骤3.3.2.1:根据如下公式更新参数 $\mathbf{B}^{k+1}$ :

$$\mathbf{B}^{k+1} = \mathfrak{D}_{\frac{\mathbf{w}_B}{\mu^k}} \left( \mathbf{D}^k - \mathbf{T}^k - \mathbf{N}^k - \frac{\mathbf{y}^k}{\mu^k} \right)$$

[0056] 其中 $\mathfrak{D}_{\tau}(\mathbf{X})$ 是奇异值收缩算子,  $\mathfrak{D}_{\tau}(\mathbf{X}) = \mathbf{U} \mathbf{S}_{\tau}(\mathbf{D}_{\mathbf{X}}) \mathbf{V}^T$ , 式中的 $\mathbf{U}$ 、 $\mathbf{D}_{\mathbf{X}}$ 、 $\mathbf{V}$ 是对矩阵 $\mathbf{X}$ 进行奇异值分解得到的,  $\mathbf{D}_{\mathbf{X}}$ 表示由其特征值组成的对角矩阵;

[0057] 步骤3.3.2.2:根据如下公式更新参数 $\mathbf{T}^{k+1}$ :

$$\mathbf{T}^{k+1} = S_{\lambda \frac{\mathbf{w}_T}{\mu^k}} \left( \mathbf{D}^k - \mathbf{B}^{k+1} - \mathbf{N}^k - \frac{\mathbf{y}^k}{\mu^k} \right)$$

[0059] 其中,  $S_{\tau}(X)$ 是软阈值收缩算子,  $S_{\tau}(X) = \text{sign}(X) \times \max(|X| - \tau, 0)$ ;

[0060] 步骤3.3.2.3:根据如下公式更新参数 $\mathbf{N}^{k+1}$ :

$$\mathbf{N}^{k+1}(:, :, i) = \begin{cases} \frac{\|\mathbf{Q}_{::,i}\|_2 - \frac{\beta^k}{\mu^k}}{\|\mathbf{Q}_{::,i}\|_2} \mathbf{Q}_{::,i} & \text{if } \|\mathbf{Q}_{::,i}\|_2 > \frac{\beta^k}{\mu^k} \\ 0 & \text{else} \end{cases}$$

[0062] 其中 $\mathbf{Q} = \mathbf{D}^k - \mathbf{B}^{k+1} - \mathbf{T}^{k+1} - \frac{\mathbf{y}^k}{\mu^k}$ ,  $\mathbf{Q}_{::,i}$ 表示用滑动窗所截取的第 $i$ 个图像块矩阵,  $\|\cdot\|_2$ 表示矩阵的二范数;

[0063] 步骤3.3.2.4:根据如下公式更新参数 $\mathbf{w}_T^{k+1}$ 、 $\mathbf{w}_B^{k+1}$ :

$$\mathbf{w}_{sw}^{k+1} = \frac{1}{|\mathbf{T}^{k+1}| + \eta}, \quad \mathbf{w}_B^{k+1} = \frac{1}{|\mathbf{B}^{k+1}| + \eta}, \text{ 其中 } \mathbf{w}_{sw}^{k+1} \text{ 是 } \mathbf{w}_T^{k+1} \text{ 中需要更新的那部分;}$$

[0065] 步骤3.3.2.5:根据如下公式更新参数 $\mathbf{y}^{k+1}$ 、 $\mu^{k+1}$ :

$$\mathbf{y}^{k+1} = \mathbf{y}^k + \mu^k (\mathbf{B}^{k+1} + \mathbf{T}^{k+1} + \mathbf{N}^{k+1} - \mathbf{D}^{k+1}), \mu^{k+1} = \min(1.05\mu^k, 10^{10});$$

[0067] 步骤3.3.2.6:将 $\mathbf{B}^{k+1}$ 和 $\mathbf{N}^{k+1}$ 都归结为背景部分, 即:  $\mathbf{B}^{k+1} = \mathbf{B}^{k+1} + \mathbf{N}^{k+1}$ ;

[0068] 步骤3.3.2.7:更新迭代次数 $k=k+1$ ;

[0069] 步骤3.3.2.8:分别计算 $\mathbf{T}^k$ 和 $\mathbf{T}^{k+1}$ 中非零元素的个数preT和currT;

[0070] 步骤3.3.2.9:判断preT和currT是否相等并且都大于0,若是则终止迭代,跳转到步骤3.3.2.10;若否,则判断公式 $\frac{\|\mathbf{B}^{k+1} + \mathbf{T}^{k+1} + \mathbf{N}^{k+1} - \mathbf{D}^{k+1}\|_F}{\|\mathbf{D}^{k+1}\|_F} < \varepsilon$ 是否成立,若成立,则终止迭代,并

跳转到步骤3.3.2.10,若不成立,则跳转到步骤3.3.2.1;

[0071] 步骤3.3.2.10:获得最优解 $\mathbf{T} = \mathbf{T}^{k+1}$ ,  $\mathbf{B} = \mathbf{B}^{k+1}$ 。

[0072] 本发明的基于加权核范数最小化的红外弱小目标检测方法的有益效果包括有:

[0073] 1、所用模型中加入了 $L_{21}$ 范数约束噪声,并对目标图像使用了加权的 $L_1$ 范数约束,创新性的提出了权重的构建方式,有效解决了现有算法中对稀疏项约束不严格导致结果被边缘、噪声、虚警源等干扰的问题;

[0074] 2、将红外小目标检测问题转化为优化问题,达到了高效、准确的分离目标和背景,提高了小目标检测的准确率;

[0075] 3、采用交替方向乘子法迭代求解,同时用到了改进的迭代终止条件,使得收敛速度大幅提升、计算运行时间大幅度减少,明显提高了应用性。

## 附图说明

[0076] 图1为本发明基于加权核范数最小化的红外弱小目标检测方法的流程图;

[0077] 图2a为本发明实施例中采用的包含小目标的红外图像;

[0078] 图2b为本发明实施例中图2a原始红外图像的三维展示;

[0079] 图3a为本发明实施例中由图2a求解得到并经过阈值分割后的目标图像;

[0080] 图3b为本发明实施例中图3a所示目标图像的三维展示;

[0081] 图4a为现有技术中红外块图像 (IPI) 模型方法对图2a处理结果的二维展示;

[0082] 图4b为现有技术中红外块图像 (IPI) 模型方法对图2a处理结果的三维展示;

[0083] 图5a为现有技术中重加权红外块张量 (RIPT) 模型方法对图2a处理结果的二维展示;

[0084] 图5b为现有技术中重加权红外块张量 (RIPT) 模型方法对图2a处理结果的三维展示。

## 具体实施方式

[0085] 以下结合附图对本发明的具体实施方式作进一步的详细说明。但不应将此理解为本发明的范围仅限于以下的实例。在不脱离本发明上述技术思想情况下,根据本领域普通技术知识和惯用手段做出的各种替换或变更,均应包括在本发明的范围内。

[0086] 如图1所示本发明基于加权核范数最小化的红外弱小目标检测方法,步骤为:

[0087] 步骤1:输入一幅大小为 $256 \times 256$ 的待处理的红外图像 $\mathbf{D} \in \mathbb{R}^{m \times n}$ ,其中 $\mathbb{R}$ 表示实数空间, $m$ 和 $n$ 分别代表待处理图像的行数和列数,通过滑动窗遍历待处理红外图像 $\mathbf{D}$ 得到红外图像块张量 $\mathbf{D} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ ,其中 $n_1 \times n_2$ 等于滑动窗的大小, $n_3$ 为滑动窗的个数;

[0088] 具体的,步骤1包括:

[0089] 步骤1.1:采用长宽尺寸为 $40 \times 40$ 、步长为40的滑动窗遍历所述红外图像 $\mathbf{D}$ ,滑动窗截取的像素在第三维度上进行堆叠构建张量;

[0090] 步骤1.2:重复步骤1.1直至遍历整幅红外图像,由此完成红外图像块张量 $\mathbf{D} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ 的构建,其中 $n_1 = n_2 = n_3 = 40$ 。

[0091] 步骤2:通过计算原始红外图像的结构张量得到两个最大的特征值,根据这两个特征值初步判断原始图像中点特征和线特征的位置来构建目标权重矩阵中的 $\mathbf{W}_0$ ,从而得到目

标权重 $W_p$ , 然后将其转化成张量的形式;

[0092] 具体的, 步骤2包括:

[0093] 步骤2.1: 根据待处理的红外图像D构建结构张量J, 其公式如下:

$$[0094] \quad J = K_\rho * (\nabla D_\sigma \otimes \nabla D_\sigma) = \begin{pmatrix} K_\rho * I_x^2 & K_\rho * I_x I_y \\ K_\rho * I_x I_y & K_\rho * I_y^2 \end{pmatrix} = \begin{pmatrix} J_{11} & J_{12} \\ J_{21} & J_{22} \end{pmatrix}$$

[0095] 其中,  $K_\rho$ 是方差为 $\rho$ 的高斯核,  $*$ 代表卷积,  $\nabla$ 表示梯度,  $\otimes$ 表示Kronecker积,  $D_\sigma$ 表示对待处理的图像用方差为 $\sigma$ 的高斯平滑滤波器进行滤波后得到的图像。 $I_x = \frac{\partial D_\sigma}{\partial x}$ ,  $I_y = \frac{\partial D_\sigma}{\partial y}$ , 分别表示 $D_\sigma$ 沿着x和y方向的梯度。

[0096] 根据结构张量获取最大的两个特征值 $\lambda_1$ 和 $\lambda_2$ , 其公式如下:

$$[0097] \quad \lambda_1 = \frac{1}{2} \left[ J_{11} + J_{22} + \sqrt{(J_{22} - J_{11})^2 + 4J_{12}^2} \right]$$

$$[0098] \quad \lambda_2 = \frac{1}{2} \left[ J_{11} + J_{22} - \sqrt{(J_{22} - J_{11})^2 + 4J_{12}^2} \right]$$

[0099] 步骤2.2: 利用 $\lambda_1$ 和 $\lambda_2$ 获取 $W_{rec}$ 和 $W_0$ , 进而得到目标权重矩阵 $W_p$ ,

[0100] 其中,  $W_{rec} = \max(\lambda_1, \lambda_2) \cdot \frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2}$ , 根据原始红外图像的特征点检测结果来分别构建点特征矩阵 $W_{point}$ 和线特征矩阵 $W_{line}$ , 从而得到矩阵 $W_0 = W_{line} + C * W_{point}$ ; 初步测试 $C=2$ 时就可以得到较好的结果, 最后可得到目标权重矩阵:  $W_p = W_{rec} \cdot W_{sw} \cdot W_0$ , 其中 $W_{sw} = \frac{1}{|T| + \eta}$ ,  $\eta=0.01$ , 在后续的迭代求解中得到更新。

[0101] 其中, 步骤2.2包括:

[0102] 步骤2.2.1: 构建特征点检测函数:

[0103]  $val = \frac{1}{2} e^{\frac{\lambda_1}{\lambda_2 + \eta} - 1} [e^{\lambda_1(\lambda_1 - \lambda_2)} + e^{\lambda_2(\lambda_1 - \lambda_2)}]$ , 该函数又可以分为两个部分:

$$val1 = e^{\frac{\lambda_1}{\lambda_2 + \eta} - 1}, \quad val2 = \frac{1}{2} [e^{\lambda_1(\lambda_1 - \lambda_2)} + e^{\lambda_2(\lambda_1 - \lambda_2)}];$$

[0104] 步骤2.2.2: 根据特征点检测函数构建点特征矩阵, 对于 $val$ 可划定阈值, 取其除了无穷大外最大值的 $\gamma_1$  (本实施例中取0.5) 倍为阈值 $seg\_val$ , 对于 $val1$ 划定阈值, 取其最小值的 $\gamma_2$  (本实施例中取100) 倍为阈值 $seg\_val1$ , 对于同时满足 $val > seg\_val$ 和 $val1 \leq seg\_val1$ 的特征点便认定为点特征, 从而将点特征矩阵相应的位置设为1, 其他的位置设为0, 由于远距离的弱小目标更易呈现出点特征, 为了保持弱小目标的形状特征, 这里需要将点特征矩阵进行形态学膨胀, 本实例中采用半径为5的圆形结构元;

[0105] 步骤2.2.3: 根据特征点检测函数构建线特征矩阵, 对于 $val$ 取值为无穷大, 而且满足 $val1 > seg\_val1$ 的特征点便认为是线特征, 从而将其线特征矩阵对应的位置设为0, 其他位置设为1;

[0106] 步骤2.3: 用滑动窗按照步骤1所述, 将目标权重矩阵 $W_p$ 堆叠成张量的形式 $\mathbf{w}_{T^*}$ 。

[0107] 步骤3: 通过加权核范数及目标权重构建目标函数, 用ADMM算法构造拉格朗日函数, 并对其求解, 得到目标图像块张量 $\mathbf{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ ;

[0108] 其中, 步骤3包括:

[0109] 步骤3.1:输入所述红外图像块张量 $\mathcal{D}$ 和目标权重图像块张量;

[0110] 步骤3.2:通过加权核范数及目标权重构建目标函数,用ADMM算法构造拉格朗日函数;

[0111] 其中,步骤3.2包括:

[0112] 步骤3.2.1:红外弱小目标图像由低秩成分的背景,稀疏成分的目标以及噪声三部分构成,由于核范数无法很好的逼近秩,所以采用加权的核范数,而目标部分添加的权重是为了更好的抑制背景,所述构建的目标函数为:

$$[0113] \quad \min_{\mathcal{B}, \mathcal{T}} \|\mathcal{B}\|_{\mathcal{W}_{\mathcal{B}},*} + \lambda \|\mathcal{T} \odot \mathcal{W}_T\|_1 + \beta \|\mathcal{N}\|_{2,1}$$

$$[0114] \quad s.t. \mathcal{D} = \mathcal{B} + \mathcal{T} + \mathcal{N}$$

[0115] 其中 $\mathcal{N}$ 代表噪声张量, $\mathcal{B}$ 代表背景张量, $\|\mathcal{A}\|_{\mathcal{W}_{\mathcal{A}},*} = \frac{1}{|\mathcal{A}|+\eta} \|\mathcal{A}\|_*$ ,这里 $\|\cdot\|_*$ 代表核范数,是对矩阵A所有的奇异值求和, $\|\mathcal{A}\|_1$ 表示张量A的 $L_1$ 范数, $\|\mathcal{A}\|_1 = \sum_i \sum_j \sum_k |\mathcal{A}(i,j,k)|$ , $\|\mathcal{N}\|_{2,1}$ 为噪声成分的 $L_{2,1}$ 范数, $\|\mathcal{N}\|_{2,1} = \sum_i \sqrt{\sum_j \sum_k \mathcal{N}(i,j,k)^2}$ , $\odot$ 表示Hadamard积, $\lambda, \beta$ 表示惩罚系数;

[0116] 步骤3.2.2:通过ADMM算法构造拉格朗日函数:

$$[0117] \quad L_{\mu}(\mathcal{D}, \mathcal{B}, \mathcal{T}, \mathcal{N}, \mathbf{y}) = \|\mathcal{B}\|_{\mathcal{W}_{\mathcal{B}},*} + \lambda \|\mathcal{T} \odot \mathcal{W}_T\|_1 + \beta \|\mathcal{N}\|_{2,1} + \langle \mathbf{y}, \mathcal{D} - \mathcal{B} - \mathcal{T} - \mathcal{N} \rangle + \frac{\mu}{2} \|\mathcal{D} - \mathcal{B} - \mathcal{T} - \mathcal{N}\|_F^2$$

[0118] 其中 $\|\cdot\|_F$ 代表Frobenius范数, $\mathbf{y}$ 表示拉格朗日乘子, $\mu$ 表示非负的惩罚因子;

[0119] 步骤3.3:求解所述的拉格朗日函数,得到目标图像块张量 $\mathcal{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ 。

[0120] 其中,步骤3.3包括:

[0121] 步骤3.3.1:初始化ADMM方程参数,迭代次数 $k=0$ , $\mathcal{T}^0 = \mathcal{B}^0 = \mathcal{N}^0 = \mathbf{y}^0 = 0$ , $\mu^0 = 0.007$ , $\mathcal{W}_{sw} = 1$ ,迭代终止阈值 $\varepsilon = 10^{-7}$ , $\lambda = 0.7/\sqrt{\max(n_1, n_2) * n_3}$ , $\beta = 0.1$ ;

[0122] 步骤3.3.2:迭代直至ADMM算法构造的拉格朗日函数收敛。

[0123] 其中,步骤3.3.2包括:

[0124] 步骤3.3.2.1:根据如下公式更新参数 $\mathcal{B}^{k+1}$ ;

$$[0125] \quad \mathcal{B}^{k+1} = \mathcal{D}_{\mathcal{W}_{\mathcal{B}}} \left( \mathcal{D}^k - \mathcal{T}^k - \mathcal{N}^k - \frac{\mathbf{y}^k}{\mu^k} \right)$$

[0126] 其中 $\mathcal{D}_{\mathcal{W}_{\mathcal{B}}}(\mathbf{X})$ 是奇异值收缩算子, $\mathcal{D}_{\mathcal{W}_{\mathcal{B}}}(\mathbf{X}) = \mathbf{U} \mathbf{S}_{\mathcal{W}_{\mathcal{B}}}(\mathbf{D}_{\mathcal{X}}) \mathbf{V}^T$ ,式中的 $\mathbf{U}, \mathbf{D}_{\mathcal{X}}, \mathbf{V}$ 是对 $\mathbf{X}$ 进行奇异值分解得到的, $\mathbf{D}_{\mathcal{X}}$ 表示由其特征值组成的对角矩阵。

[0127] 步骤3.3.2.2:根据如下公式更新参数 $\mathcal{T}^{k+1}$ ;

$$[0128] \quad \mathcal{T}^{k+1} = \mathcal{S}_{\lambda \mathcal{W}_T} \left( \mathcal{D}^k - \mathcal{B}^{k+1} - \mathcal{N}^k - \frac{\mathbf{y}^k}{\mu^k} \right)$$

[0129] 其中, $\mathcal{S}_{\tau}(X)$ 是软阈值收缩算子, $\mathcal{S}_{\tau}(X) = \text{sign}(X) \times \max(|X| - \tau, 0)$ ;

[0130] 步骤3.3.2.3:根据如下公式更新参数 $\mathcal{N}^{k+1}$ ;

$$[0131] \quad \mathcal{N}^{k+1}(:, :, i) = \begin{cases} \frac{\|\mathcal{Q}_{::,i}\|_2 - \frac{\beta^k}{\mu^k}}{\|\mathcal{Q}_{::,i}\|_2} \mathcal{Q}_{::,i} & \text{if } \|\mathcal{Q}_{::,i}\|_2 > \frac{\beta^k}{\mu^k} \\ 0 & \text{else} \end{cases}$$

[0132] 其中  $\mathcal{Q} = \mathcal{D}^k - \mathcal{B}^{k+1} - \mathcal{T}^{k+1} - \frac{\mathbf{y}^k}{\mu^k}$ ,  $\mathcal{Q}_{::,i}$  表示用滑动窗所截取的第  $i$  个图像块矩阵,  $\|\cdot\|_2$  表示矩阵的二范数;

[0133] 步骤3.3.2.4:根据如下公式更新参数  $\mathbf{w}_T^{k+1}$ 、 $\mathbf{w}_B^{k+1}$ ;

[0134]  $\mathbf{w}_{sw}^{k+1} = \frac{1}{|\mathcal{T}^{k+1}| + \eta}$ ,  $\mathbf{w}_B^{k+1} = \frac{1}{|\mathcal{B}^{k+1}| + \eta}$ , 其中  $\mathbf{w}_{sw}^{k+1}$  是  $\mathbf{w}_T^{k+1}$  中需要更新的那部分。

[0135] 步骤3.3.2.5:根据如下公式更新参数  $\mathbf{y}^{k+1}$ 、 $\mu^{k+1}$ ;

[0136]  $\mathbf{y}^{k+1} = \mathbf{y}^k + \mu^k (\mathcal{B}^{k+1} + \mathcal{T}^{k+1} + \mathcal{N}^{k+1} - \mathcal{D}^{k+1})$ ,  $\mu^{k+1} = \min(1.05\mu^k, 10^{10})$

[0137] 步骤3.3.2.6:将  $\mathcal{B}^{k+1}$  和  $\mathcal{N}^{k+1}$  都归结为背景部分, 即:  $\mathcal{B}^{k+1} = \mathcal{B}^{k+1} + \mathcal{N}^{k+1}$ ;

[0138] 步骤3.3.2.7:更新迭代次数  $k = k + 1$ ;

[0139] 步骤3.3.2.8:分别计算  $\mathcal{T}^k$  和  $\mathcal{T}^{k+1}$  中非零元素的个数  $\text{preT}$  和  $\text{currT}$ ;

[0140] 步骤3.3.2.9:判断  $\text{preT}$  和  $\text{currT}$  是否相等并且都大于0, 若是则终止迭代, 跳转到步骤3.3.2.10; 若否, 则判断公式  $\frac{\|\mathcal{B}^{k+1} + \mathcal{T}^{k+1} + \mathcal{N}^{k+1} - \mathcal{D}^{k+1}\|_F}{\|\mathcal{D}^{k+1}\|_F} < \varepsilon$  是否成立, 若成立则终止迭代, 并

跳转到步骤3.3.2.10; 若不成立则跳转到步骤3.3.2.1。

[0141] 步骤3.3.2.10:获得最优解  $\mathcal{T} = \mathcal{T}^{k+1}$ ,  $\mathcal{B} = \mathcal{B}^{k+1}$ 。

[0142] 步骤4:将所述目标图像块张量  $\mathcal{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$  重构回目标图像  $\mathbf{T} \in \mathbb{R}^{m \times n}$ :将红外图像块张量中的每个正面切片按顺序重构成  $256 \times 256$  的目标图像  $\mathbf{T} \in \mathbb{R}^{m \times n}$ , 对于重叠的部分采用均值滤波的方式决定该位置的像素值。

[0143] 步骤5:将所述目标图像  $\mathbf{T} \in \mathbb{R}^{m \times n}$  进行阈值分割, 获取检测结果:对所述重构的目标图像  $\mathbf{T} \in \mathbb{R}^{m \times n}$  进行自适应阈值分割, 阈值  $\text{Th} = \mu + c \cdot \sigma$ , 其中  $\mu$  表示输入红外图像的均值,  $\sigma$  为输入红外图像的标准差,  $c$  表示常数, 本实例中  $c = 3$ , 分割完成后获取检测结果。

[0144] 根据附图进行效果分析:图2a为一副红外图像, 小目标处于道路的边缘, 且背景较为复杂, 除了包含小目标外还有一些小石子在路边, 而且道路边缘很显著, 这些对目标检测都有着极大的干扰, 图2b是原始图像的三维展示, 可以看出干扰特别大; 图3a是用本发明中的方法得到的经过阈值分割后的目标图像, 图3b是其三维展示, 可以看到除了目标区域外, 响应都为0; 图4~5分别为现有技术中的红外块图像 (IPI) 模型和重加权红外块张量 (RIPT) 模型对图2a处理并经过阈值分割后结果的二维展示和三维展示, IPI方法存在较多的杂波干扰从而引起虚警多, 而RIPT方法产生了误检, 杂波干扰部分的存在使得目标得到了弱化; 通过对比可以看到, 现有的两种方法的处理结果都有杂波干扰, 而本发明的方法只有目标区域有响应, 因此不仅可以降低虚警率, 还可以提高目标检测的准确率。

[0145] 以上所述, 仅为本发明的具体实施方式, 但本发明的保护范围并不局限于此, 这些实施例仅仅是为了说明的目的, 而并非为了限制本发明的范围。本发明的范围由所附权利要求及其等价物限定。不脱离本发明的范围, 本领域技术人员可以做出多种替代和修改, 这些替代和修改都应落在本发明的范围之内。

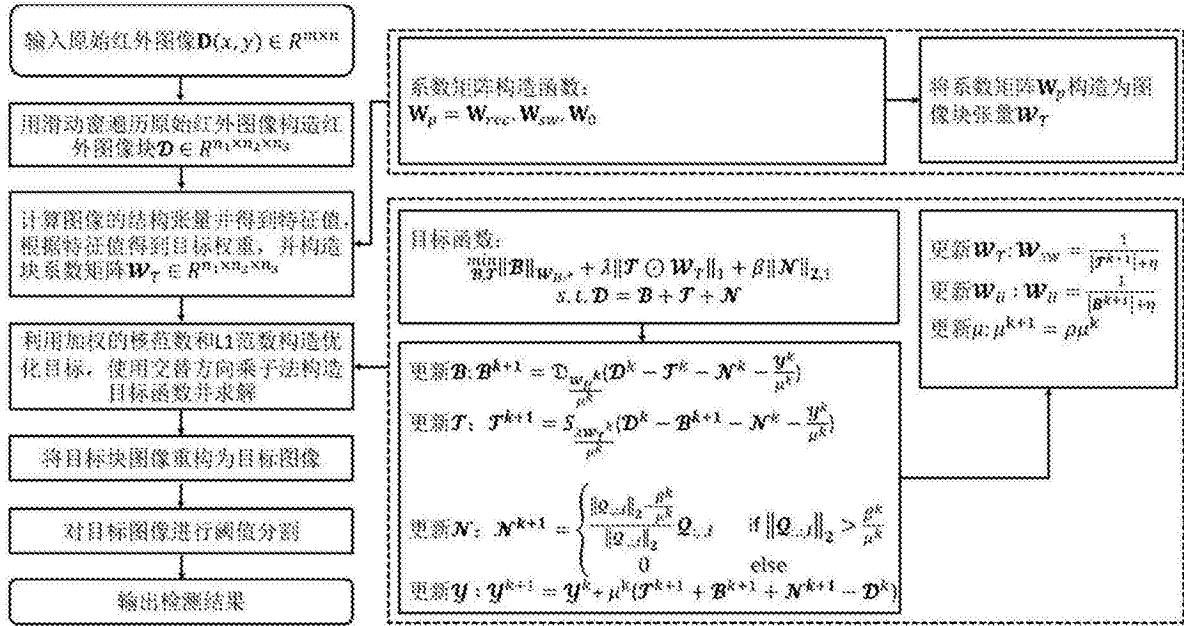


图1




图2a




图2b




图3a




图3b




图4a






图4b




图5a




图5b